Statistics For Finance And Insurance

REAL ESTATE PRICES AND MARKETING DATASET

Claudio Raffaele Salerno
Davide Gaito
Francesco Esposito

Real Estate Prices Prediction and Logistic Regression on Marketing Dataset

Francesco Esposito, Claudio Raffaele Salerno, Davide Gaito

2024-05-21

Contents

ANALISI DI REGRESSIONE MULTIPLA **2**

Introduzione **2**

EDA **2**

Analisi di regressione multipla **11**

Analisi dei Residui **14**

Verifica dei punti influenti **17**

Verifica delle assunzioni di Gauss-Markov **20**

ANALISI DI REGRESSIONE LOGISTICA **26**

Introduzione **26**

Analisi di regressione logistica **31**

Conclusioni **37**

ANALISI DI REGRESSIONE MULTIPLA

```
#impostiamo la working directory
setwd("C:/Users/Lenovo/OneDrive/Desktop/progetto R")
```

Introduzione

Il set di dati è costituito dai prezzi delle case negli Stati Uniti; si compone di 4548 osservazioni e 6 variabili. Controlliamo rapidamente le variabili presenti:

- **Avg. Area Income** : dati numerici relativi alla zona media di reddito in cui è ubicata la casa in unità di $;
- **HouseAge** : età della casa espressa in anni;
- **Number of Rooms**: numero di stanze/vani;
- **Number of Bedrooms** : numero di camere da letto;
- **AreaPopulation** : popolazione unitaria della zona in cui si trova la casa;
- **Price** : prezzo degli immobili in unità di $.

EDA

Carichiamo le librerie:

```
library(readr)    #lettura dati
library(corrplot) #visualizzazione  matrice di correlazione
library(ggplot2)  #migliore visualizzazione  dei grafici
library(cowplot)  #collegato a ggplot2, fornisce grafici migliori
library(lmtest)   #test del modello di regressione lineare
library(car)      #QQplot
library(sandwich) #analisi di regressione con stime robuste
library(GGally)   #grafici più accurati
library(pscl)     #per McFadden R^2
library(caret)    #ConfusionMatrix
library(ROCR)     #funzione di previsione per calcolare ROC e AUC
library(dplyr)    #accorpare livelli variabili categoriche
```

Carichiamo i Dati:

```
house <- read_csv("House_Price.csv")
```

```
## Rows: 4548 Columns: 6
## -- Column specification --------------------------------------------------------
## Delimiter: ","
## dbl (6): Avg. Area Income, House Age, Number of Rooms, Number of Bedrooms, A...
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
View(house)
```

Controllo la struttura dei dati e la corretta natura delle variabili:

```
str(house)
```

```
## spc_tbl_ [4,548 x 6] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ Avg. Area Income  : num [1:4548] 79545 79249 61287 63345 59982 ...
##  $ House Age         : num [1:4548] 5.68 6 5.87 7.19 5.04 ...
##  $ Number of Rooms   : num [1:4548] 7.01 6.73 8.51 5.59 7.84 ...
##  $ Number of Bedrooms: num [1:4548] 4.09 3.09 5.13 3.26 4.23 4.04 3.41 2.42 2.3 6.1 ...
##  $ Area Population   : num [1:4548] 23087 40173 36882 34310 26354 ...
##  $ Price             : num [1:4548] 1059034 1505891 1058988 1260617 630943 ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   `Avg. Area Income` = col_double(),
##   ..   `House Age` = col_double(),
##   ..   `Number of Rooms` = col_double(),
##   ..   `Number of Bedrooms` = col_double(),
##   ..   `Area Population` = col_double(),
##   ..   Price = col_double()
##   .. )
##  - attr(*, "problems")=<externalptr>
```

```
head(house)
```

```
## # A tibble: 6 x 6
##   `Avg. Area Income` `House Age` `Number of Rooms` `Number of Bedrooms`
##                <dbl>       <dbl>             <dbl>                <dbl>
## 1             79545.        5.68              7.01                 4.09
## 2             79249.        6.00              6.73                 3.09
## 3             61287.        5.87              8.51                 5.13
## 4             63345.        7.19              5.59                 3.26
## 5             59982.        5.04              7.84                 4.23
## 6             80176.        4.99              6.10                 4.04
## # i 2 more variables: `Area Population` <dbl>, Price <dbl>
```

Controllo le statistiche descrittive:

```
summary(house)
```

```
##  Avg. Area Income   House Age     Number of Rooms  Number of Bedrooms
##  Min.   : 17797   Min.   :2.644   Min.   : 3.236   Min.   :2.000
##  1st Qu.: 61485   1st Qu.:5.332   1st Qu.: 6.300   1st Qu.:3.140
##  Median : 68817   Median :5.961   Median : 7.002   Median :4.050
##  Mean   : 68612   Mean   :5.979   Mean   : 6.988   Mean   :3.982
##  3rd Qu.: 75821   3rd Qu.:6.658   3rd Qu.: 7.666   3rd Qu.:4.490
##  Max.   :107702   Max.   :9.519   Max.   :10.760   Max.   :6.500
##  Area Population       Price
##  Min.   :  172.6   Min.   :  15939
##  1st Qu.:29423.2   1st Qu.: 997775
##  Median :36215.6   Median :1234571
##  Mean   :36187.5   Mean   :1233916
##  3rd Qu.:42880.6   3rd Qu.:1470616
##  Max.   :69592.0   Max.   :2469066
```

Verifico se ci sono valori mancanti:

```
cat("Ci sono valori mancanti?" , any(is.na(house)))
```

```
## Ci sono valori mancanti? FALSE
```

Rinominiamo le variabili al fine di rendere più snella la procedura di coding:

```
income=house$`Avg. Area Income`
age=house$`House Age`
n.rooms=house$`Number of Rooms`
n.bedrooms=house$`Number of Bedrooms`
area.population=house$`Area Population`
price=house$Price
```

Vediamo come sono distribuite graficamente le variabili oggetto di analisi:

Distribuzioni di densità:

```
kernel.income=ggplot(house, aes(x=income)) + geom_density() +
theme_gray(base_size = 10)

kernel.age=ggplot(house, aes(x=age)) + geom_density() +
theme_gray(base_size = 10)

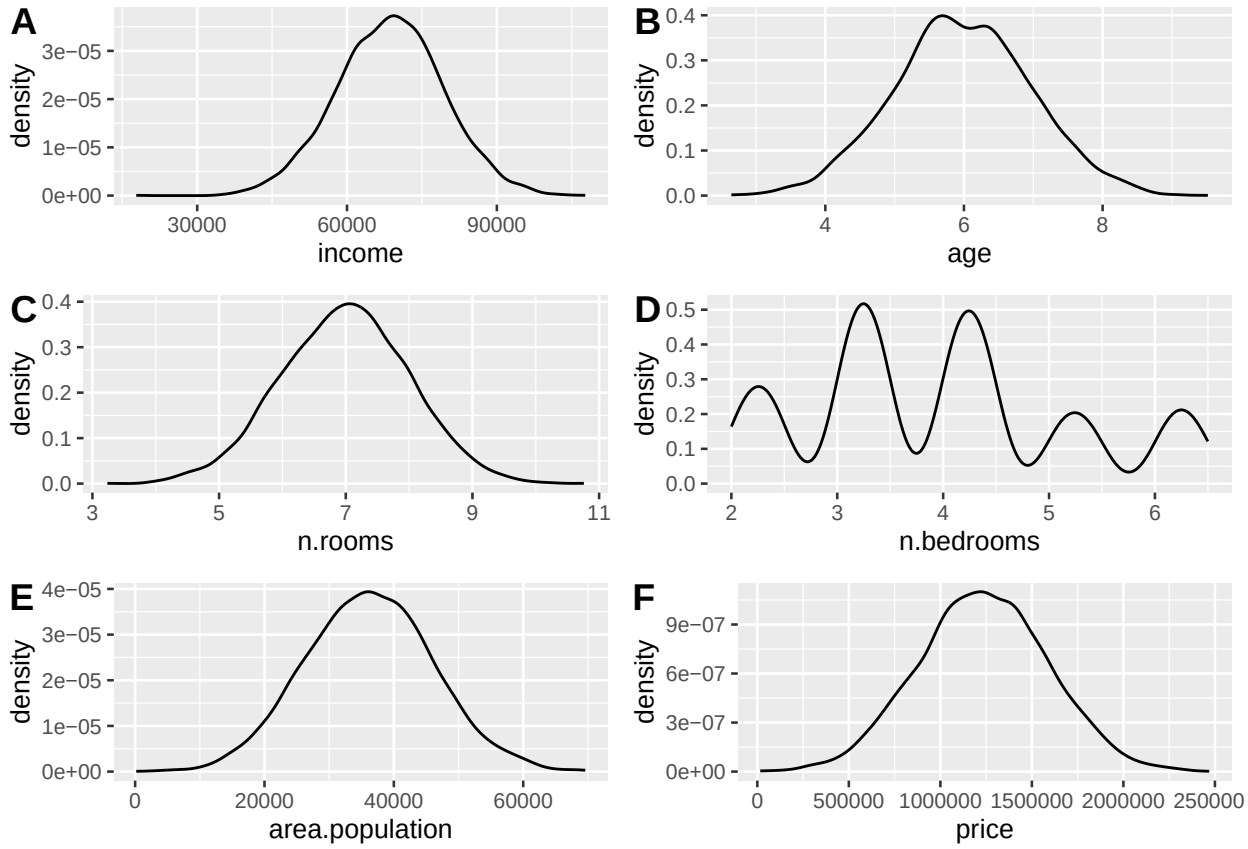
kernel.n.rooms=ggplot(house, aes(x=n.rooms)) + geom_density() +
theme_gray(base_size = 10)

kernel.n.bedrooms=ggplot(house, aes(x=n.bedrooms)) + geom_density() +
theme_gray(base_size = 10)

kernel.area.population=ggplot(house, aes(x=area.population)) +
geom_density() + theme_gray(base_size = 10)

kernel.price=ggplot(house, aes(x=price)) + geom_density() +
theme_gray(base_size = 10)

plot_grid(kernel.income, kernel.age, kernel.n.rooms, kernel.n.bedrooms,
      kernel.area.population, kernel.price, labels="AUTO", nrow = 3, ncol = 2)
```



Analizzando queste distribuzioni, possiamo ottenere importanti informazioni sulle caratteristiche delle variabili indipendenti che influenzeranno il nostro modello di regressione. In particolare:

- **Income**: La distribuzione del reddito medio mostra una forma monomodale con un picco intorno alle 60.000 unità di reddito. Questo suggerisce che la maggior parte dei soggetti ha un reddito che si aggira a questa cifra. La distribuzione è relativamente simmetrica, il che è utile per la modellizzazione;
- **HouseAge**: La distribuzione dell'età media delle case mostra una leggera bimodalità, con due picchi principali tra i 5 e i 6 anni. Questo potrebbe indicare che esistono due gruppi distinti di età delle case nel dataset;
- **N.Rooms**: La distribuzione del numero di stanze è monomodale con un picco intorno a 7 stanze. Questo indica che la maggior parte delle case ha circa 7 stanze;
- **N.Bedrooms**: La distribuzione del numero di camere da letto è multimodale con diversi picchi distinti. Questo potrebbe indicare la presenza di segmenti distinti di case con diverse configurazioni di camere da letto;
- **AreaPopulation**: La distribuzione della popolazione nell'area mostra una forma monomodale con un picco intorno ai 40.000 individui;
- **Price**: La distribuzione del prezzo delle case mostra una forma monomodale con un picco intorno ai 500.000 unità di prezzo. La distribuzione relativamente simmetrica è favorevole per l'analisi di regressione;

Boxplot:

```
box.income=ggplot(house, aes(x=income)) + geom_boxplot() +
  theme_gray(base_size = 10)

box.age=ggplot(house, aes(x=age)) + geom_boxplot() +
  theme_gray(base_size = 10)

box.n.rooms=ggplot(house, aes(x=n.rooms)) + geom_boxplot() +
  theme_gray(base_size = 10)

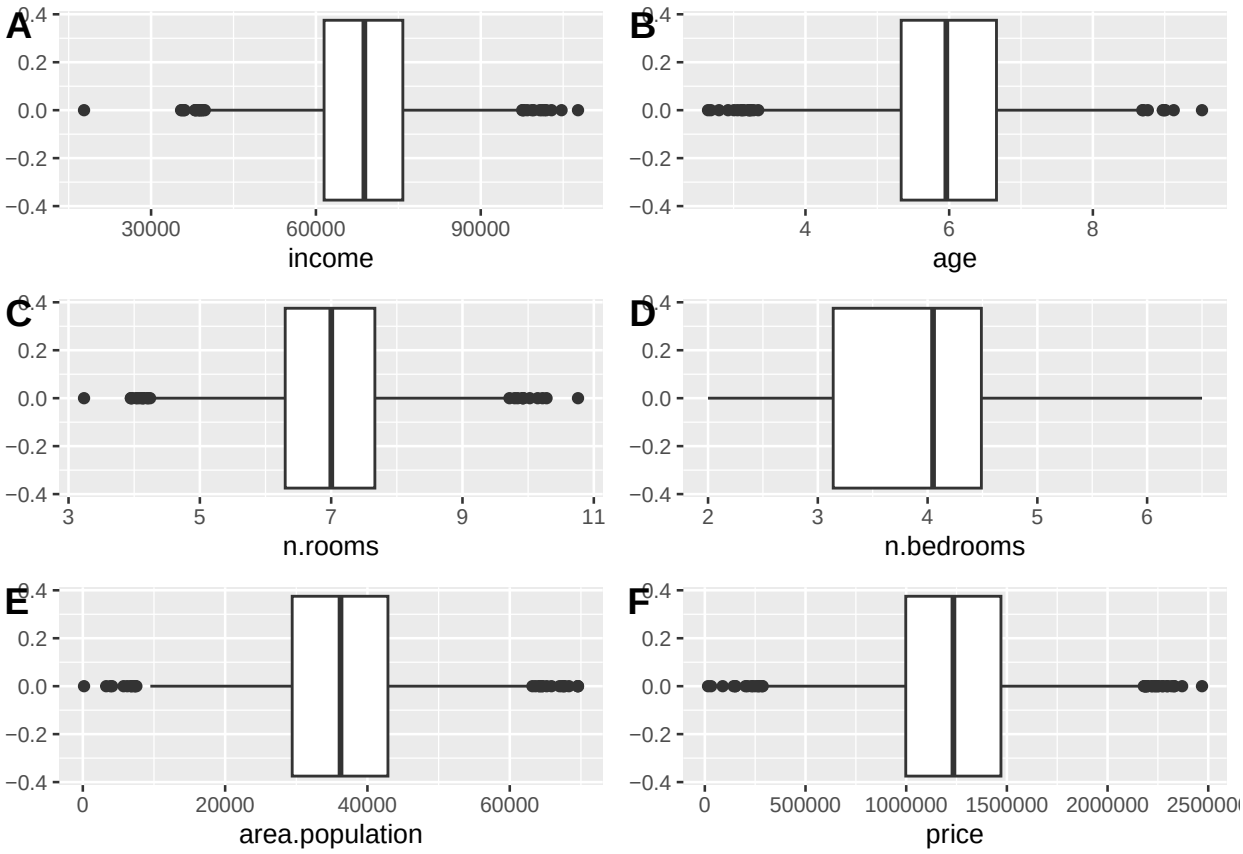
box.n.bedrooms=ggplot(house, aes(x=n.bedrooms))+ geom_boxplot() +
  theme_gray(base_size= 10)

box.n.bedrooms=ggplot(house, aes(x=n.bedrooms))+ geom_boxplot() +
  theme_gray(base_size= 10)

box.area.population=ggplot(house, aes(x=area.population))+ geom_boxplot() +
  theme_gray(base_size= 10)

box.price=ggplot(house, aes(x=price))+ geom_boxplot() +
  theme_gray(base_size= 10)

plot_grid(box.income, box.age, box.n.rooms, box.n.bedrooms, box.area.population,
          box.price, labels="AUTO", nrow = 3, ncol = 2)
```



La visualizzazione dei boxplot delle variabili del dataset ci permette di ottenere una panoramica iniziale della distribuzione dei dati e di identificare eventuali anomalie o valori anomali (outliers).

In particolare:

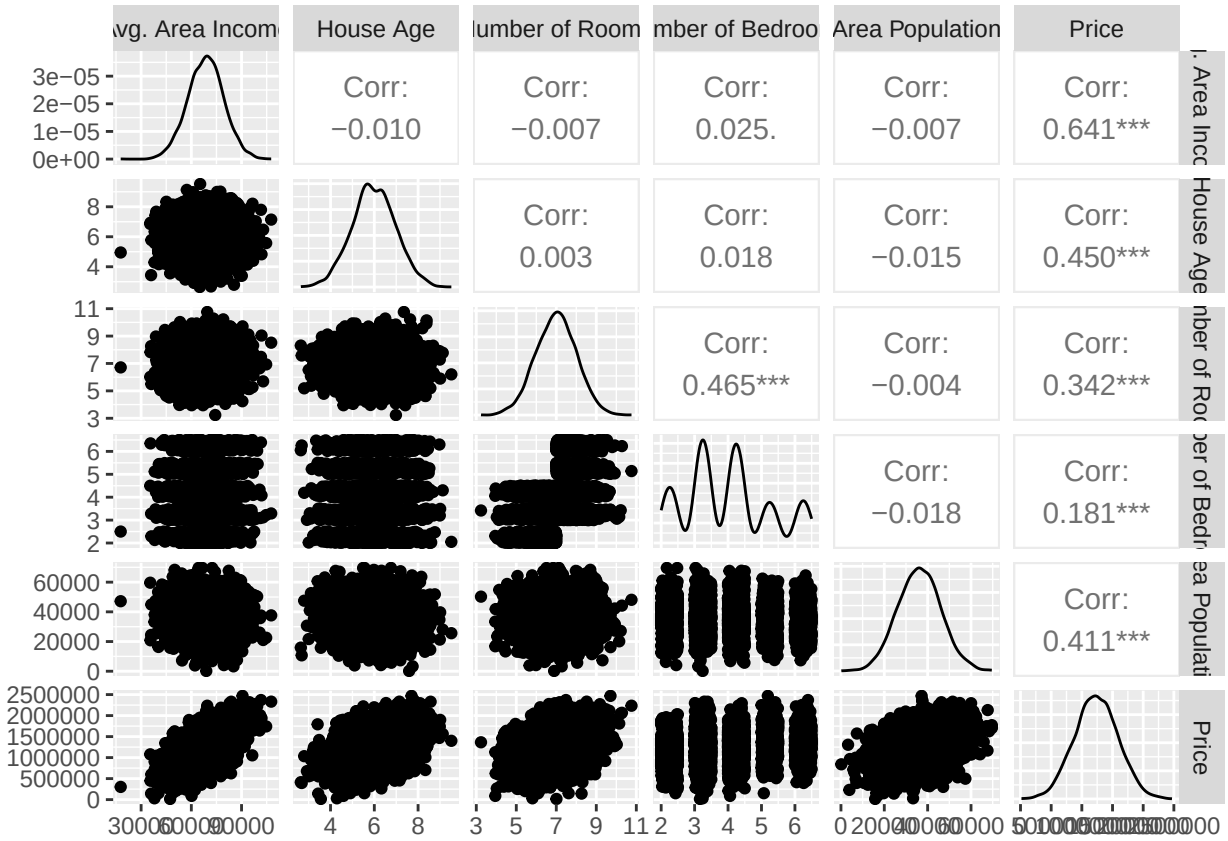
I vari boxplot evidenziano una distribuzione simmetrica per le variabili, le quali presentano una concentrazione intorno alla mediana e quindi una minima dispersione. Inoltre, in tutte, eccetto N.Bedrooms, sono presenti degli outliers che indicano valori più alti o più bassi della variabili rispetto all'intero campione. Nel caso di N.Bedrooms, invece, gli outliers sono presenti verso l'alto indicando case con un numero di camere da letto significativamente maggiore.

Ora rileviamo la correlazione tra le variabili:

```
cor(house)
```

```
##                     Avg. Area Income    House Age Number of Rooms
## Avg. Area Income         1.000000000 -0.010143260    -0.006591518
## House Age               -0.010143260  1.000000000     0.002683159
## Number of Rooms         -0.006591518  0.002683159     1.000000000
## Number of Bedrooms       0.024653775  0.017728397     0.464564938
## Area Population         -0.007291989 -0.014899518    -0.003877480
## Price                    0.641381623  0.450133626     0.341572876
##                     Number of Bedrooms Area Population     Price
## Avg. Area Income             0.02465378    -0.007291989 0.6413816
## House Age                    0.01772840    -0.014899518 0.4501336
## Number of Rooms              0.46456494    -0.003877480 0.3415729
## Number of Bedrooms           1.00000000    -0.018172432 0.1813707
## Area Population             -0.01817243     1.000000000 0.4114532
## Price                        0.18137070     0.411453184 1.0000000
```

```
ggpairs(as.data.frame(house))
```



Innanzitutto, abbiamo utilizzato il comando GGpairs per ottenere:

- **visualizzazione distribuzione variabili**: in modo tale che le diagonali mostrino le densità delle singole variabili al fine di avere un'idea della loro distribuzione;

- **esaminazione delle relazione tra le variabili**: gli scatter plots mostrano le relazione bivariate tra ogni coppia di variabili; mentre le correlazioni mostrano i coefficienti di correlazione tra le variabili per comprendere forza e direzione della loro relazione lineare;
- **identificazione di pattern e anomalie**: al fine di ottenere una identificazione più chiara di tendenze o outliers, che possono essere importanti per l'analisi dei dati;

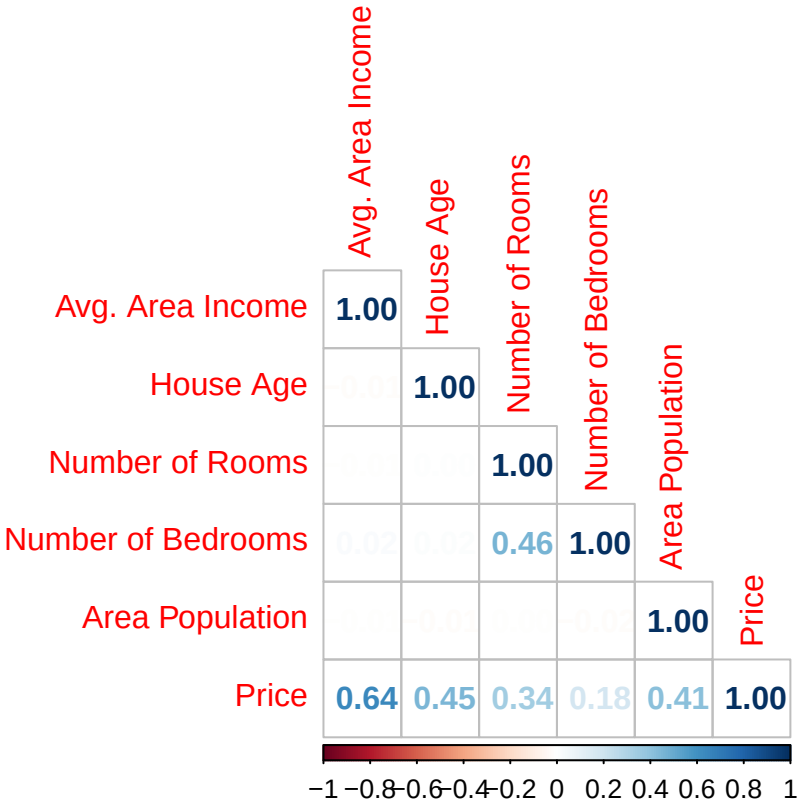
Per quanto riguarda la correlazione tra variabile dipendente e quelle indipendenti, si evince che:

- rispetto a **Avg.Area.Income**: presenta un coefficiente di correlazione pari a 0.641. La forte correlazione positiva suggerisce che il reddito medio dell'area è un preditorre significativo del prezzo delle case;
- rispetto a **House Age**: presenta coefficiente di correlazione pari a 0.450. Vi è una moderata correlazione positiva, ciò indica che all'aumentare dell'età delle case si hanno prezzi più elevati. Una nostra considerazione, non conoscendo di preciso il luogo di rilevazione delle osservazioni, è che potrebbe trattarsi di case considerate di rilievo storico e quindi avere un valore aggiunto per la loro età e/o carattere distintivo; o, ancora, di case situate vicino ai principali servizi funzionali al benessere psicofisico dell'acquirente;
- rispetto a **Number of Rooms**: presenta coeffciente di correlazione pari a 0.342. Per cui, vi è moderata correlazione positiva, ciò indica che case con più stanze presentano un prezzo più elevato;
- rispetto a **Number of Bedrooms**: presenta coefficiente di correlazione pari a 0.181. Vi è debole correlazione positiva, ciò suggerisce che il numero di camere da letto ha un'influenza minore sul prezzo delle case rispetto alle altre variabili;
- rispetto a **Area Population**: presenta coefficiente di correlazione pari a 0.411. Vi è, quindi, moderata correlazione positiva, il che suggerisce che una più alta popolazione nell'area è associata a prezzi delle case più elevate.

Mentre, analizzando la relazione tra le variabili indipendenti, notiamo che:

- Le variabili "Number of Rooms" e "Number of Bedrooms" hanno una correlazione positiva moderata (0.46). Questo è logico poiché le case con più stanze tendono ad avere anche più camere da letto.
- La variabile "Avg. Area Income" non mostra correlazioni significative con altre variabili indipendenti, suggerendo che è una variabile relativamente indipendente.

```
corrplot(cor(house), method="number", type="lower")
```



La matrice di correlazione conferma quanto analizzato in precedenza con GGpairs.

Analisi di regressione multipla

Ora passiamo all'implementazione di un modello di analisi di regressione multipla, il quale ha come variabile dipendente il prezzo, al fine di verificare la possibile influenza delle variabili indipendenti su di esso.

Per prima cosa dividiamo il dataset in Training Set, pari al 70% delle osservazioni e Testing Set, pari al restante 30% delle osservazioni.

```
set.seed(500)
sample=sample(c(TRUE, FALSE), nrow(house), replace=TRUE, prob=c(0.7,0.3))
train=house[sample, ]
test=house[!sample, ]
```

successivamente, stimiamo il modello:

```
stima1 <- lm(formula = Price ~ ., data = train)
summary(stima1)
```

```
##
## Call:
## lm(formula = Price ~ ., data = train)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -340548  -71353   -1352   70111  322591
##
## Coefficients:
##                         Estimate Std. Error  t value Pr(>|t|)
## (Intercept)          -2.643e+06  2.170e+04 -121.810   <2e-16 ***
## `Avg. Area Income`    2.168e+01  1.685e-01  128.647   <2e-16 ***
## `House Age`           1.663e+05  1.847e+03   90.058   <2e-16 ***
## `Number of Rooms`     1.218e+05  2.069e+03   58.858   <2e-16 ***
## `Number of Bedrooms` -6.861e+02  1.661e+03   -0.413     0.68
## `Area Population`     1.512e+01  1.840e-01   82.143   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 102200 on 3172 degrees of freedom
## Multiple R-squared:  0.9177, Adjusted R-squared:  0.9175
## F-statistic:  7069 on 5 and 3172 DF,  p-value: < 2.2e-16
```

Dal summary, osserviamo che:

- L'intercetta è altamente significativa e rappresenta il valore atteso del prezzo delle case quando tutte le variabili indipendenti sono uguali a zero. Questo valore non ha un'interpretazione pratica diretta poiché alcune variabili come il reddito medio dell'area e la popolazione dell'area non possono realisticamente essere zero;
- Un aumento di una unità nel reddito medio dell'area è associato a un aumento di 21.68 unità nel prezzo delle case, ceteris paribus. Questa variabile è altamente significativa;
- Un anno in più nell'età della casa è associato a un aumento di 166,300 unità nel prezzo delle case, ceteris paribus. Questa variabile è altamente significativa;

- Una stanza in più è associata a un aumento di 121,800 unità nel prezzo delle case, ceteris paribus. Questa variabile è altamente significativa;
- il numero di camere da letto non è significativo, indicando che non ha un impatto statistico significativo sul prezzo delle case, ceteris paribus;
- Un'unità in più nella popolazione dell'area è associata a un aumento di 15.12 unità nel prezzo delle case, ceteris paribus. Questa variabile è altamente significativa;

i risultati confermano l'output della matrice di correlazione.

Per quanto riguarda, invece, l'analisi di R^2, Adjusted R^2, F-Statistic e Residual Standard Error, possiamo dire che:

- **Residual Standard Error**, pari a 102200, che rappresenta la deviazione standard dei residui, di base dovrebbe essere un valore basso. In questo caso, però, è influenzato dai prezzi delle case che sono in unità di migliaia, per cui possiamo comunque considerarlo accetabile;
- **Multiple R-squared**: 0.9177 Indica che circa il 91.77% della variabilità nei prezzi delle case è spiegata dalle variabili indipendenti del modello;
- **Adjusted R-squared**: 0.9175 Simile al Multiple R-squared, ma aggiustato per il numero di predittori nel modello. Un valore elevato indica un buon adattamento del modello;
- **F-statistic**: 7069 su 5 e 3172 gradi di libertà con p-value: <2.2e-16 Un valore F alto e un p-value molto basso indicano che il modello complessivo è altamente significativo.

Poichè la variabile "Number of Bedrooms" non è significativa, procediamo con la sua rimozione dal modello e effettuiamo una nuova stima in questo senso:

```
stima2 <- lm(formula = Price ~ `Avg. Area Income` + `House Age` +
               `Number of Rooms` + `Area Population`, data = train)
summary(stima2)
```

```
##
## Call:
## lm(formula = Price ~ `Avg. Area Income` + `House Age` + `Number of Rooms` +
##     `Area Population`, data = train)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -339561  -71512   -1094   70437  321362
##
## Coefficients:
##                       Estimate Std. Error t value Pr(>|t|)
## (Intercept)        -2.643e+06  2.169e+04 -121.86   <2e-16 ***
## `Avg. Area Income`  2.167e+01  1.684e-01  128.74   <2e-16 ***
## `House Age`         1.663e+05  1.846e+03   90.08   <2e-16 ***
## `Number of Rooms`   1.214e+05  1.830e+03   66.30   <2e-16 ***
## `Area Population`   1.512e+01  1.839e-01   82.22   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 102100 on 3173 degrees of freedom
## Multiple R-squared:  0.9176, Adjusted R-squared:  0.9175
## F-statistic:  8839 on 4 and 3173 DF,  p-value: < 2.2e-16
```

Ora tutti i coefficienti sono significativamente diversi da 0.

Successivamente analizziamo gli intervalli di confidenza, essi ci forniscono una gamma di valori entro cui ci aspettiamo che cadano i veri coefficienti della popolazione con un certo livello di confidenza (in questo caso, il 95%).

```
confint(stima2,level=0.95)
```

```
##                              2.5 %        97.5 %
## (Intercept)         -2.685112e+06 -2.600070e+06
## `Avg. Area Income`   2.134334e+01  2.200353e+01
## `House Age`          1.626646e+05  1.699030e+05
## `Number of Rooms`    1.177660e+05  1.249437e+05
## `Area Population`    1.475918e+01  1.548035e+01
```

Tutti i coefficienti tranne l'intercetta sono significativamente diversi da zero con un livello di confidenza del 95%.

Questi risultati confermano che le variabili incluse nel modello spiegano una parte significativa della variazione nei prezzi delle case e che le stime dei coefficienti sono robuste.

```
cov.m=vcov(stima2)
cov.m
```

```
##                      (Intercept) `Avg. Area Income`   `House Age`
## (Intercept)        470300177.459      -1.974628e+03 -2.070547e+07
## `Avg. Area Income`     -1974.628       2.834313e-02  5.502990e+00
## `House Age`        -20705474.217       5.502990e+00  3.407212e+06
## `Number of Rooms`  -23166472.911      -2.167583e+00 -2.494259e+04
## `Area Population`      -1252.292       2.538756e-04  3.019139e+00
##                    `Number of Rooms` `Area Population`
## (Intercept)            -2.316647e+07     -1.252292e+03
## `Avg. Area Income`     -2.167583e+00      2.538756e-04
## `House Age`            -2.494259e+04      3.019139e+00
## `Number of Rooms`       3.350285e+06     -1.668289e-01
## `Area Population`      -1.668289e-01      3.382075e-02
```

Analisi dei Residui

Calcoliamo valori stimati e residui e generiamo una tabella contenente questi ultimi per le prime 12 osservazioni del dataset;

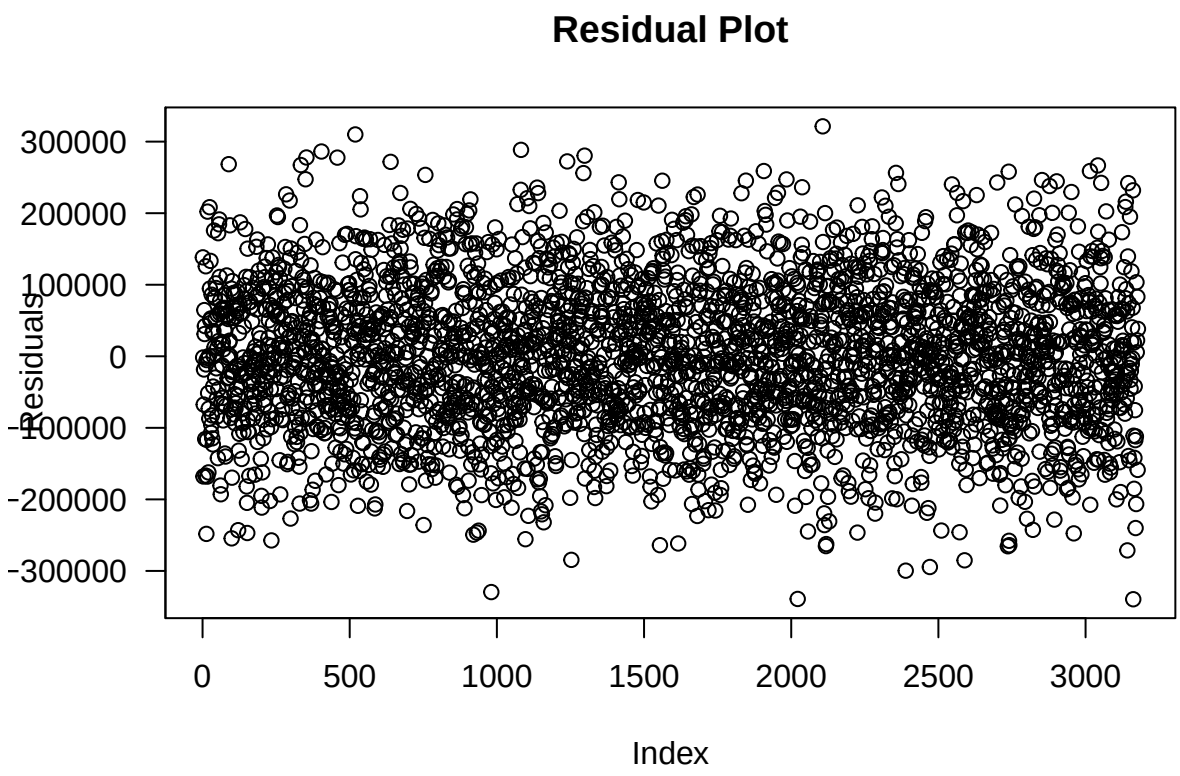
```
fitted_values = stima2$fitted.values
residual = stima2$residuals
head(cbind(train[,-1], fitted_values, residual), 12)
```

```
##    House Age Number of Rooms Number of Bedrooms Area Population     Price
## 1   7.188236        5.586729                3.26        34310.24 1260616.8
## 2   4.988408        6.104512                4.04        26748.43 1068138.1
## 3   6.025336        8.147760                3.41        60828.25 1502055.8
## 4   8.093513        5.042747                4.10        47224.36 1707045.7
## 5   6.919535        5.993188                2.27        32326.12 1291331.5
## 6   5.443156        8.517513                4.01        23929.52 1306674.7
## 7   5.067890        8.219771                3.12        39717.81 1556786.6
## 8   4.788550        5.097010                4.30        24595.90  528485.2
## 9   5.947165        7.187774                5.12        35719.65 1019425.9
## 10  5.739411        7.091808                5.49        44922.11 1030591.4
## 11  6.627457        8.011898                4.07        47560.78 2146925.3
## 12  4.210323        5.478088                4.31        40358.96  718887.2
##    fitted_values   residual
## 1      1122344.4  138272.44
## 2      1069826.3   -1688.19
## 3      1670041.4 -167985.53
## 4      1774518.7  -67473.01
## 5      1309789.0  -18457.47
## 6      1242119.5   64555.20
## 7      1525673.4   31113.24
## 8       486314.1   42171.19
## 9      1135110.6 -115684.70
## 10     1197218.0 -166626.56
## 11     2021146.8  125778.53
## 12      730261.7  -11374.49
```

Il modello sembra avere una buona precisione generale, con alcuni residui relativamente piccoli (come nelle osservazioni 2 e 12), ma ci sono anche alcune predizioni con residui più grandi (come nelle osservazioni 1, 3, 9 e 10). I residui negativi indicano che il modello ha sovrastimato il prezzo reale, mentre residui positivi indicano una sottostima. Alcuni di questi sono significativamente grandi, suggerendo che ci possono essere outliers.

Successivamente procediamo al plot dei residui per valutare la bontà di adattamento del modello; apportando, però, una modifica al fine di eliminare la notazione esponenziale sull'asse delle ordinate:

```
# correzione notazione
plot(residual, ylab = "Residuals", xlab = "Index", main = "Residual Plot", axes = FALSE)
axis(1)
axis(2, at = pretty(residual), labels = format(pretty(residual), scientific = FALSE),
     las = 1)
box()
```



Il grafico dei residui suggerisce che il modello di regressione multipla è generalmente appropriato per i dati, infatti: i residui sono distribuiti intorno allo zero e non sembra esserci un pattern evidente in essi, il che è un buon segno e suggerisce che il modello non lascia sistematicamente fuori alcune componenti della variabilità dei dati. Di conseguenza, anche la varianza è abbastanza costante, infatti possiamo notare una dispersione uniforme sopra e sotto l'asse orizzontale: un primo indicatore di omoschedasticità.

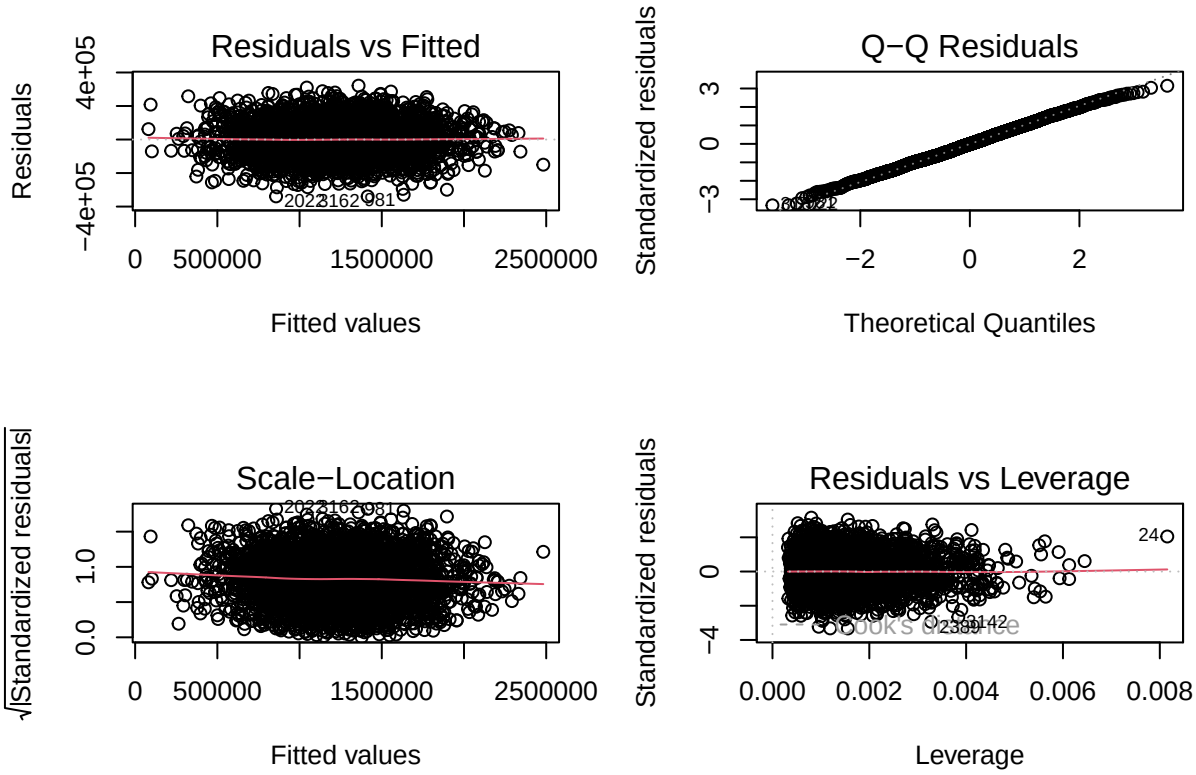
Prima di passare alla verifica delle assunzioni di Gauss-Markov, calcoliamo:

```
# i gradi di libertà
df=df.residual(stima2)
# varianza stimata
s.hat=t(residual)%*%residual/df
# errore standard residuo (RSE)
rse=sqrt(s.hat)
# residui standardizzati
sres=residual/rse
```

```
## Warning in residual/rse: Il riciclo di array di lunghezza 1 in array-vettori aritmetici è deprecato.
##   Utilizza piuttosto c() o as.vector().
```

Successivamente andiamo a plottare la diagnostica del nostro modello:

```
par(mfrow=c(2,2))
plot(stima2)
```



- **Residual Vs Fitted Values**: il primo grafico, che mostra i residui sull'asse verticale e i valori stimati su quella orizzontale, suggerisce che i residui si distribuiscono casualmente intorno alla linea orizzontale a zero, ciò indica che il modello cattura correttamente la relazione tra la variabile dipendente e quelle indipendenti; inoltre, avendo una dispersione abbastanza uniforme lungo l'intervallo di valori stimati, suggerisce che l'ipotesi di omoschedasticità è rispettata;
- **Q-Q Plot**: confronta i quantili dei residui standardizzati con i quantili di una distribuzione normale. In questo caso, la maggior parte dei punti si allinea lungo la linea dell'intervallo di riferimento, ciò indica che i residui sono approssimativamente normali; le deviazioni alle code indica la presenza di una leggera non normalità dei residui a causa degli outliers;
- **Scale-Location**: questo grafico mostra la radice quadrata dei residui standardizzati rispetto ai valori stimati (fitted values). La linea rossa è orizzontale e la distribuzione dei punti è abbastanza uniforme lungo l'asse dei valori stimati. Questo indica che la varianza dei residui è costante (omoschedasticità), una delle assunzioni fondamentali della regressione lineare.
- **Residuals vs Leverage**: questo grafico mostra i residui standardizzati rispetto al leverage[1], che misura l'influenza di ogni punto sull'adattamento del modello. Include anche le linee di Cook's distance. Punti con alto leverage (a destra del grafico) indicano osservazioni che hanno un'influenza significativa sul modello. Mentre, punti al di fuori delle linee di Cook's distance suggeriscono che queste osservazioni hanno un'influenza sproporzionata sulle stime dei parametri e dovrebbero essere esaminati attentamente;

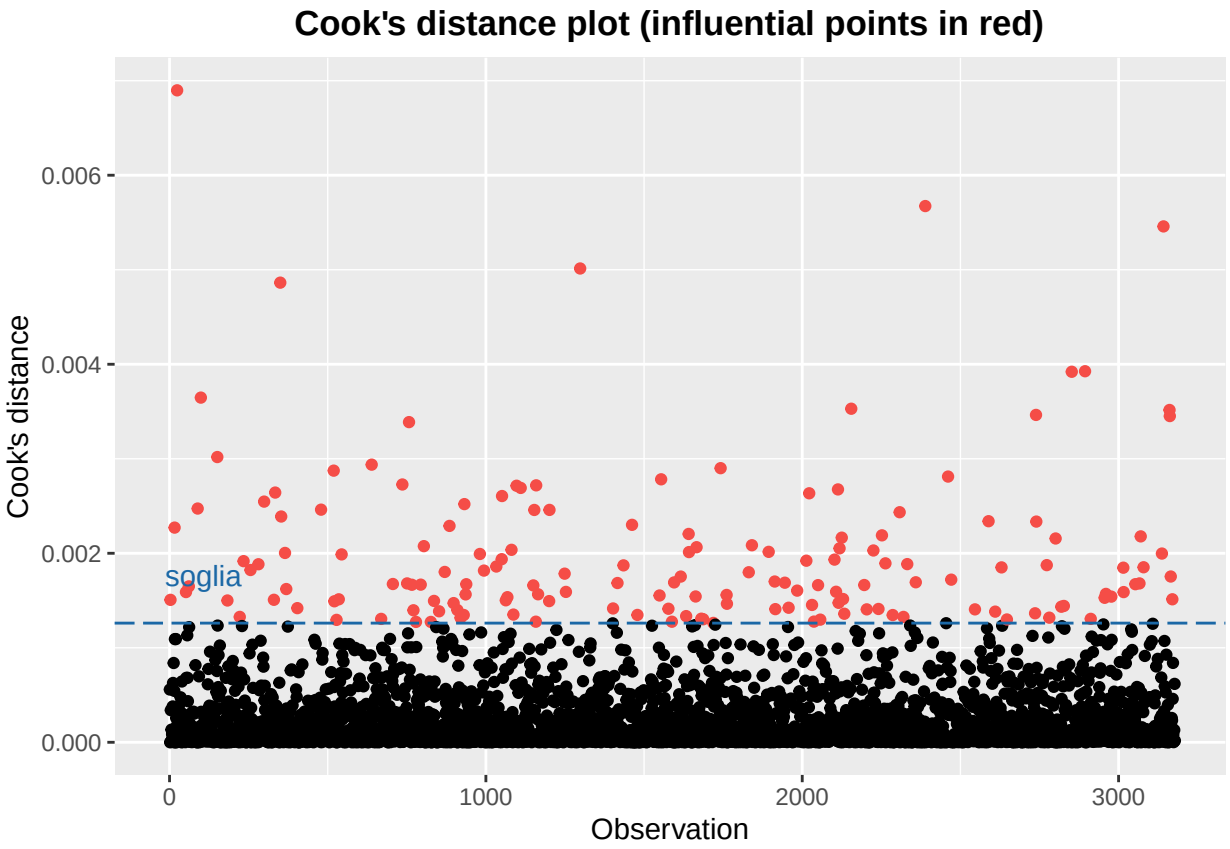
[1]Il leverage è una misura che indica quanto una singola osservazione (un punto di dati) è distante dalla media delle variabili indipendenti. In un modello di regressione, il leverage aiuta a identificare punti che hanno un'influenza sproporzionata sul modello.

Nel complesso, i grafici diagnostici suggeriscono che il modello di regressione multipla è generalmente appropriato per i dati, con residui che mostrano una distribuzione casuale e una varianza costante.

Verifica dei punti influenti

Per verificare la presenza di punti influenti andremo a misurare la Cook's distance e se essa è maggiore della soglia impostata, allora consideriamo il punto come influente:

```
# utilizziamo la soglia come criterio per determinare quali osservazione del dataset
# hanno un'influenza significativa sui parametri stimati del modello di regressione
soglia <- 4 / (nrow(train) - length(stima2$coefficients) - 1)
# Calcolo della distanza di Cook
cookd <- cooks.distance(stima2)
# Identificazione degli outliers
outliers <- as.numeric(names(cookd)[cookd > soglia])
# Creazione di un indice per le osservazioni
index <- seq(1:length(stima2$residuals))
# Creazione del dataframe per il grafico
cookdf <- data.frame(cookd, index)
# Creazione del grafico con ggplot2
ggplot(cookdf, aes(x = index, y = cookd, color = cookd > soglia)) +
  geom_point() +
  scale_color_manual(values = c("black", "#F54D47")) +
  geom_hline(yintercept = soglia, linetype = "longdash", colour = "#1B68A6") +
  annotate("text", x = min(index) - 15, y = soglia + 0.0005,
           label = "soglia", colour = "#1B68A6", hjust = 0) +
  theme(legend.position = "none",
        plot.title = element_text(face = 'bold', hjust = 0.5)) +
  ggtitle("Cook's distance plot (influential points in red)") +
  labs(x = "Observation", y = "Cook's distance")
```



- i punti rossi sono le osservazioni che hanno una distanza di Cook superiore alla soglia. Questi sono potenzialmente influenti e possono avere un grande impatto sui coefficienti stimati del modello. Al contrario, i punti neri sono le osservazioni che hanno una distanza di Cook inferiore alla soglia e sono considerate non influenti;
- La maggior parte delle osservazioni ha una distanza di Cook relativamente bassa (vicina a zero), indicando che la questi non sono influenti in maniera sproporzionata sul modello. Al contempo, c'è un numero limitato di osservazioni che ha una distanza di Cook elevata, indicando che questi punti devono essere esaminati più da vicino per capire perché sono così influenti.
- La linea tratteggiata blu rappresenta una soglia comune per identificare le osservazioni influenti. Tipicamente, essa è fissata, per ragioni pratiche e convenzionali, a $\frac{4}{N-k-1}$. Le osservazioni che superano tale soglia possono indicare outliers o punti di dati che non sono ben spiegati dal modello.

Ora procediamo alla stima del modello, dopo l'eliminazione dei punti influenti:

```
clean_data <- train[-outliers, ]

reg_clean <- lm(sqrt(train$Price) ~ sqrt(train$`Avg. Area Income`) +
                sqrt(train$`House Age`) + sqrt(train$`Number of Rooms`) +
                sqrt(train$`Area Population`), data=clean_data)

summary(reg_clean)
```

```
##
```

```
## Call:
## lm(formula = sqrt(train$Price) ~ sqrt(train$`Avg. Area Income`) +
##     sqrt(train$`House Age`) + sqrt(train$`Number of Rooms`) +
##     sqrt(train$`Area Population`), data = clean_data)
##
## Residuals:
##     Min      1Q  Median      3Q     Max
## -354.97  -31.80    0.09   34.14  163.19
##
## Coefficients:
##                                 Estimate Std. Error t value Pr(>|t|)
## (Intercept)                   -2.453e+03  2.139e+01 -114.65   <2e-16 ***
## sqrt(train$`Avg. Area Income`)  5.238e+00  4.375e-02  119.71   <2e-16 ***
## sqrt(train$`House Age`)         3.755e+02  4.488e+00   83.66   <2e-16 ***
## sqrt(train$`Number of Rooms`)   2.965e+02  4.828e+00   61.41   <2e-16 ***
## sqrt(train$`Area Population`)   2.585e+00  3.384e-02   76.39   <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 51.33 on 3173 degrees of freedom
## Multiple R-squared:  0.9056, Adjusted R-squared:  0.9055
## F-statistic:  7607 on 4 and 3173 DF,  p-value: < 2.2e-16
```

Se effettuaimo un confronto con il summary precedente, possiamo notare che il modello senza outliers è molto più stabile. Infatti, con la trasformazione delle variabili e la rimozione dei valori influenti, fornisce stime più precise e riduce l'impatto dei valori estremi.

Ad esempio, un primo confronto può essere effettuato per l'R^2:

il Modello senza outlier presenta un R^2 di 0.9056 (Adjusted $R^2 = 0.9055$), mentre il modello con outlier ha un $R^2 = 0.9176$ (Adjusted $R^2 = 0.9175$). Ciò suggerisce che il Modello con outlier ha un R^2 leggermente più alto, indicando una maggiore percentuale di varianza spiegata dai predittori, probabilmente dovuta all'inclusione dei valori influenti.

Se volessimo analizzare gli errori standard, invece, possiamo notare che:

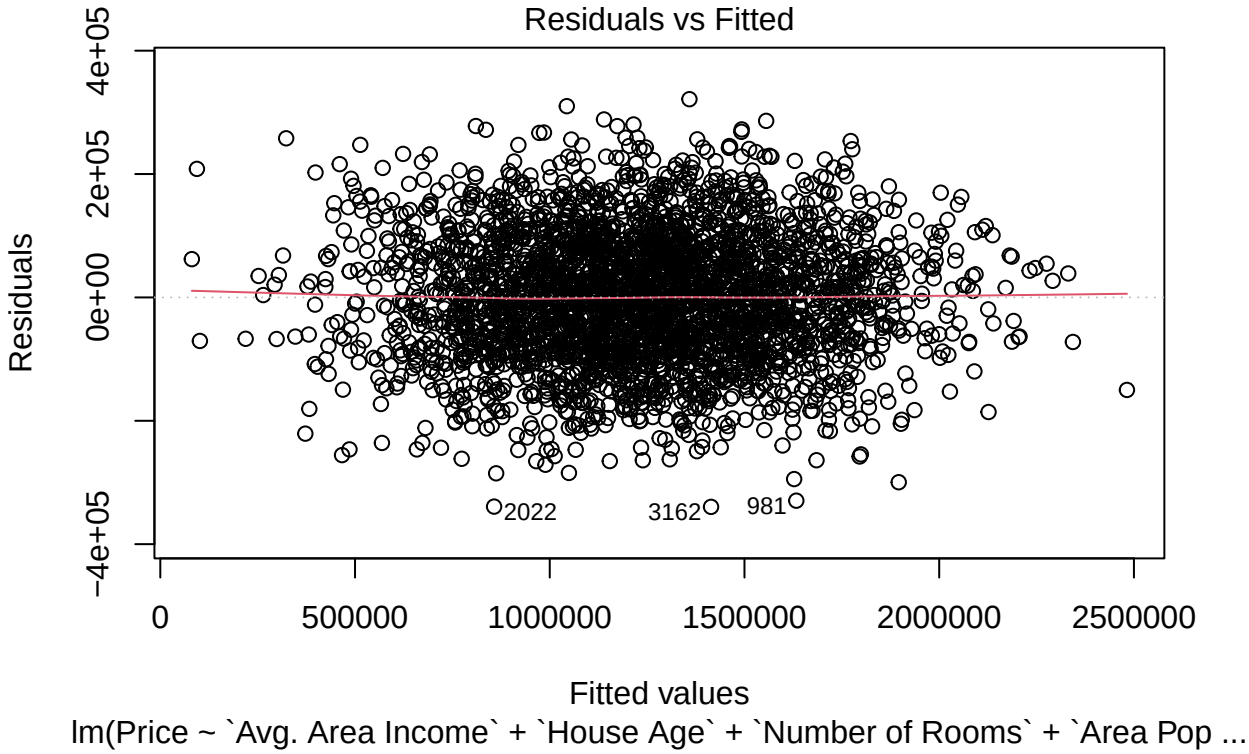
il modello senza outlier ha Residual standard error = 51.33 mentre l'altro ha Residual standard error = 102100. L'errore standard dei residui è molto più basso nel Modello senza outlier, suggerendo una migliore precisione delle stime dopo la rimozione dei valori influenti.

Anche il coefficiente dell'intercetta è molto più basso, Modello senza outlier è -2453, Modello con outlier è -2643000, la grande differenza nell'intercetta è dovuta alla scala delle variabili e alla trasformazione applicata nel Modello senza outlier.

Verifica delle assunzioni di Gauss-Markov

A.1) **Specificazione corretta**: secondo il primo grafico della diagnostica, ossia Residual Vs Fitted, possiamo affermare che il modello è specficato correttamente, per cui lo richiamiamo;

```
plot(stima2, c(1))
```



A.2) **Media dei residui uguale a 0**: $E(\epsilon_i) = 0, \forall i$___

```
t.test(residual)
```

```
##
##  One Sample t-test
##
## data:  residual
## t = 9.8385e-16, df = 3177, p-value = 1
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
##  -3550.273  3550.273
## sample estimates:
##    mean of x
## 1.781468e-12
```

il p-value è uguale a 1, quindi, accettiamo l'ipotesi nulla tale per cui la media dei residui è statisticamente pari a 0;

A.3) **Omoschedasticità**: $Var(\epsilon_i) = \sigma^2, \forall i$___

L'omoscedasticità implica che la varianza dei residui è costante per tutti i valori delle variabili indipendenti. Se questa ipotesi non è soddisfatta (cioè, se i residui mostrano eteroscedasticità), allora le inferenze statistiche basate sul modello di regressione potrebbero essere non affidabili.

In questo caso abbiamo verificato la presenza di omoschedasticità con due metodi:

- **Primo test: Breusch-Pagan Test**:

```
bptest(stima2, data=train)
```

```
##
##  studentized Breusch-Pagan test
##
## data:  stima2
## BP = 5.2567, df = 4, p-value = 0.262
```

Il risultato suggerito dal p-value che in questo caso è pari a 0.262, quindi maggiore di 0.05, è che non ci sono prove sufficienti per rifiutare l'ipotesi nulla. Per cui non possiamo rifiutare l'ipotesi di omoscedasticità.

- **Secondo Test: White Test**:

```
# Calcolo dei residui al quadrato
residual2 <- residual^2

# Creazione di un nuovo dataframe con i residui al quadrato
newhouse <- cbind(train, residual2)
head(newhouse)
```

```
##   Avg. Area Income House Age Number of Rooms Number of Bedrooms Area Population
## 1         63345.24  7.188236        5.586729               3.26        34310.24
## 2         80175.75  4.988408        6.104512               4.04        26748.43
## 3         64698.46  6.025336        8.147760               3.41        60828.25
## 4         80527.47  8.093513        5.042747               4.10        47224.36
## 5         73163.66  6.919535        5.993188               2.27        32326.12
## 6         73091.87  5.443156        8.517513               4.01        23929.52
##     Price   residual2
## 1 1260617 19119268451
## 2 1068138     2849985
## 3 1502056 28219139849
## 4 1707046  4552607468
## 5 1291332   340678259
## 6 1306675  4167374237
```

```
# Assegnazione delle variabili indipendenti
i <- train$`Avg. Area Income`
H <- train$`House Age`
R <- train$`Number of Rooms`
A <- train$`Area Population`

# Modello ausiliario per il test di White
aux.reg <- lm(residual2 ~ i + H + R + A + I(i^2) + I(H^2) + I(R^2) + I(A^2)+
                i*H + i*R + i*A + H*R + H*A + R*A, newhouse)
summary(aux.reg)
```

```
##
## Call:
## lm(formula = residual2 ~ i + H + R + A + I(i^2) + I(H^2) + I(R^2) +
##     I(A^2) + i * H + i * R + i * A + H * R + H * A + R * A, data = newhouse)
##
## Residuals:
##        Min         1Q     Median         3Q        Max
## -1.321e+10 -9.101e+09 -5.287e+09  3.491e+09  1.062e+11
##
## Coefficients:
##               Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.429e+10  2.498e+10   0.572    0.567
## i           -1.735e+05  3.075e+05  -0.564    0.573
## H            2.310e+09  3.526e+09   0.655    0.512
## R            6.639e+08  3.421e+09   0.194    0.846
## A           -2.646e+05  3.201e+05  -0.826    0.409
## I(i^2)       2.389e+00  1.476e+00   1.618    0.106
## I(H^2)      -1.437e+08  1.864e+08  -0.771    0.441
## I(R^2)      -1.033e+08  1.840e+08  -0.561    0.575
## I(A^2)      -7.352e-01  1.842e+00  -0.399    0.690
## i:H         -2.644e+04  2.365e+04  -1.118    0.264
## i:R         -2.643e+03  2.299e+04  -0.115    0.908
## i:A         -3.535e-01  2.374e+00  -0.149    0.882
## H:R          9.220e+06  2.570e+08   0.036    0.971
## H:A          2.139e+04  2.494e+04   0.858    0.391
## R:A          2.792e+04  2.522e+04   1.107    0.268
##
## Residual standard error: 1.405e+10 on 3163 degrees of freedom
## Multiple R-squared:  0.003872,   Adjusted R-squared:  -0.0005368
## F-statistic: 0.8783 on 14 and 3163 DF,  p-value: 0.5826
```

```r
# Calcolo del valore R^2
R2 <- summary(aux.reg)$r.squared

# Numero di osservazioni
n <- nrow(newhouse)

# Statistica del test di White
stat.test <- n * R2

# Poiché la statistica del test è distribuita asintoticamente come una
# variabile casuale Chi-quadrato con k gradi di libertà, dove k = numero di
# coefficienti - 1,
# per calcolare il p-value e decidere sulla presenza di eteroschedasticità,
# dobbiamo implementare il comando pchisq()

# Calcolo dei gradi di libertà
df <- length(aux.reg$coefficients) - 1

# Calcolo del p-value del test di White
p_value <- pchisq(stat.test, df = df, lower.tail = FALSE)

# Visualizzazione del p-value
p_value
```

```
## [1] 0.5817443
```

Il risultato ottenuto dal modello di regressione ausiliario utilizzato per il White test mostra alcuni punti importanti da considerare:

- L'R^2 è estremamente basso (0.003872), indicando che il modello spiega una quantità molto piccola della variabilità nei residui al quadrato. Inoltre, l'Adjusted R^2 è negativo (-0.0005368), il che può avvenire quando l'R^2 del modello è molto basso ed ha troppi parametri rispetto alla quantità di dati disponibili;
- Osservando i p-value associati ai coefficienti, vediamo che nessuno dei termini è statisticamente significativo al livello di significatività comune (ad esempio, 0.05);
- Il p-value ottenuto è 0.5817, che è molto più alto del livello di significatività comune (ad esempio, 0.05). Pertanto, non possiamo rigettare l'ipotesi nulla di omoschedasticità (costanza della varianza dei residui). In altre parole, non ci sono prove sufficienti per affermare che esista eteroschedasticità nei residui del modello.

A.4) **No Autocorrelazione**: $Cov(\epsilon_i, \epsilon_l) = 0, \forall i \neq l$___

La verifica dell'autocorrelazione dei residui è particolarmente rilevante per i dati temporali (serie temporali). Pertanto, avendo dati cross-sectional non abbiamo valutato questa ipotesi.

A.5) **Assenza di multicollinearità**:

La multicollinearità si verifica quando due o più variabili indipendenti in un modello di regressione sono altamente correlate tra loro. Questo può causare problemi nella stima dei coefficienti del modello, rendendoli instabili e difficili da interpretare.

Per verificare l'assenza di multicollinearità, possiamo calcolare il Variance Inflation Factor (VIF) per ciascuna variabile indipendente:

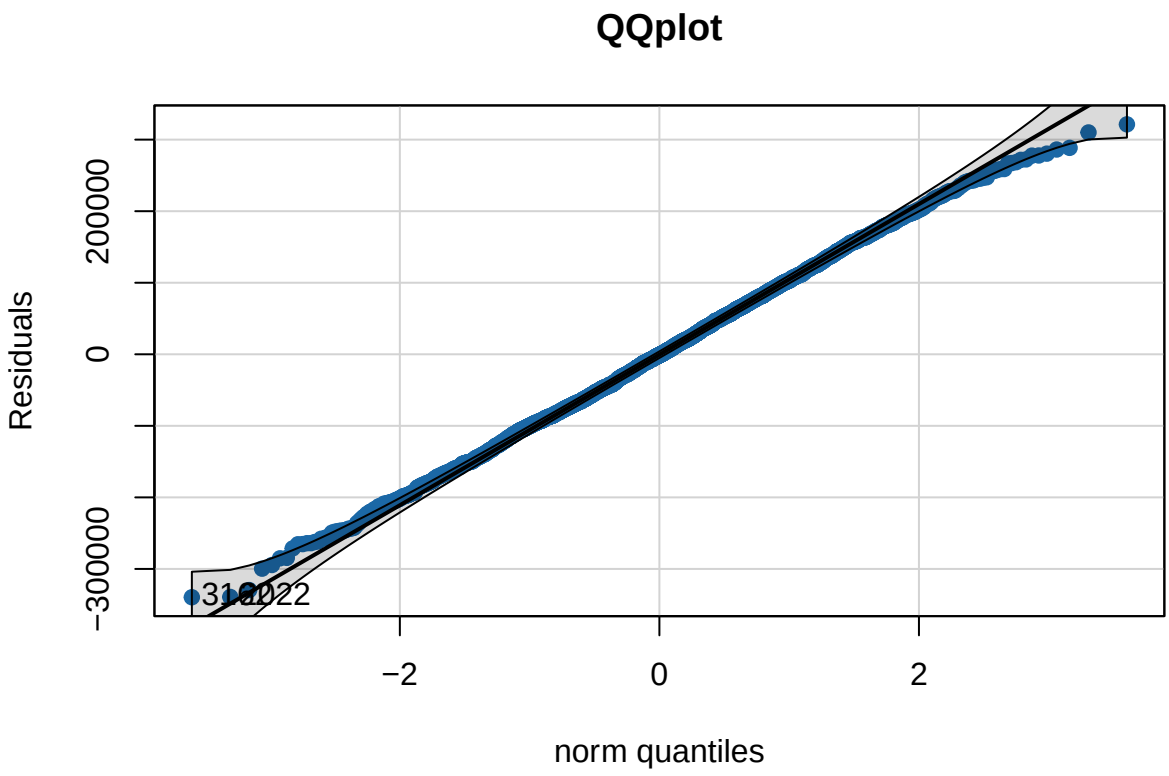
```
vif(stima2)
```

```
## ‘Avg. Area Income‘        ‘House Age‘  ‘Number of Rooms‘  ‘Area Population‘
##           1.000426           1.000443           1.000102           1.000144
```

un VIF vcino all'1 per tutte le variabili indipendenti indica che c'è assenza di multicollinearità.

A.6) **Normalità dei residui**: $\epsilon_i \sim N(0, \sigma^2), \forall i$___

```
options(scipen = 999)
qqPlot(stima2$residual, main = "QQplot", ylab = "Residuals",
       col.lines = "black", pch = 19, col = "#1B68A6")
```




```
## [1] 3162 2022
```

Siccome i punti nel Q-Q plot si allineano lungo la linea di riferimento, possiamo affermare che i residui seguono una distribuzione normale.

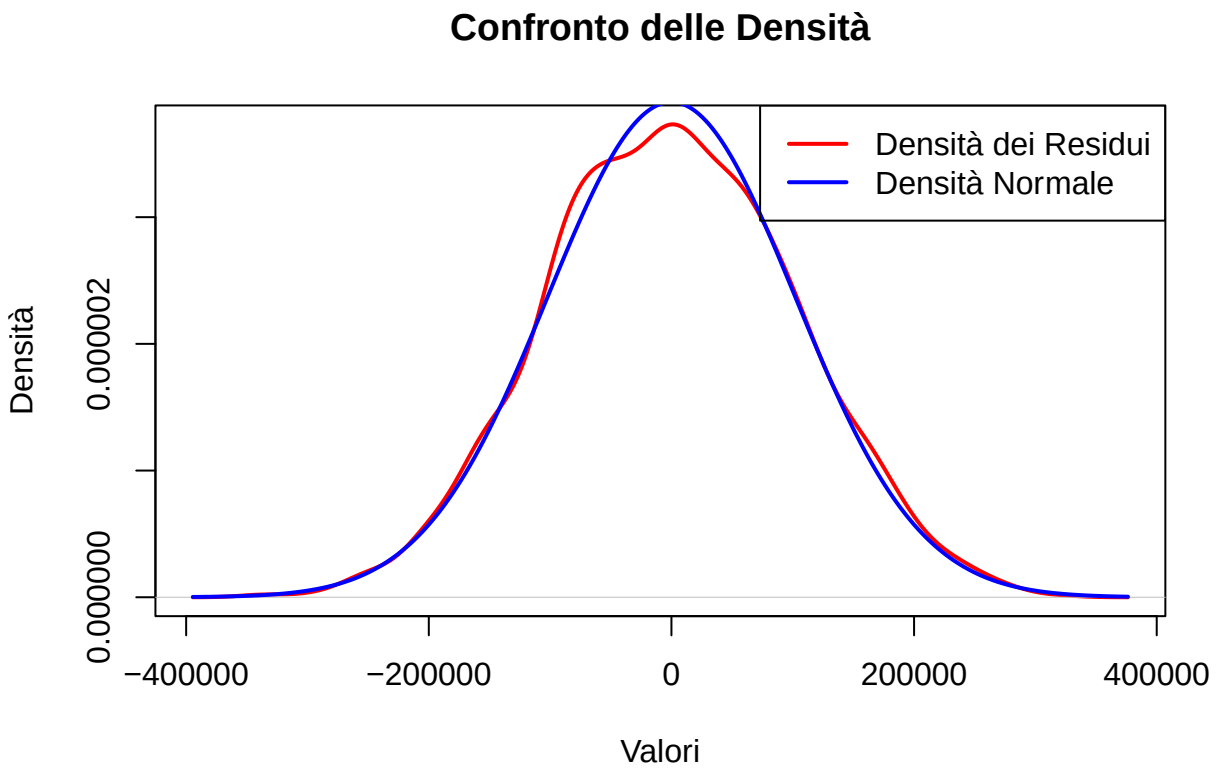
A conferma di quanto verificato sopra, compariamo la densità dei residui con la densità della distribuzione normale:

```r
# Calcolo della densità dei residui
density_residuals <- density(residual)

# Creazione di una distribuzione normale con la stessa media e deviazione standard
# dei residui
mean_residuals <- mean(residual)
sd_residuals <- sd(residual)
normal_density <- dnorm(density_residuals$x, mean = mean_residuals, sd = sd_residuals)

# Creazione del grafico
plot(density_residuals, main = "Confronto delle Densità", xlab = "Valori",
     ylab = "Densità", col = "red", lwd = 2)
lines(density_residuals$x, normal_density, col = "blue", lwd = 2)

# Aggiunta della legenda
legend("topright", legend = c("Densità dei Residui", "Densità Normale"),
       col = c("red", "blue"), lwd = 2)
```



Il grafico mostra che i residui del modello di regressione seguono approssimativamente una distribuzione normale, con solo lievi deviazioni visibili nelle code della distribuzione. Questo suggerisce che le assunzioni di normalità per i residui sono in gran parte rispettate, supportando la validità del modello di regressione.

ANALISI DI REGRESSIONE LOGISTICA

Introduzione

Il dataset utilizzato per questa analisi rappresenta il risultato di una campagna di marketing effettuata da un istituo bancario portoghese e riporta il dettaglio degli utenti che hanno sottoscritto o meno un deposito a termine.

Il set di dati contiene 8 variabili con le seguenti informazioni:

Informazioni sul cliente:

- **age**: età del cliente (numerica);
- **balance**: bilancio annuale medio, in euro (numerica);

Informazioni sull'ultimo contatto durante la campagna marketing

- **day**: giorno dell'ultimo contatto (numerica);
- **duration**: durata dell'ultimo contatto, in secondi (numerica);

Altri attributi:

- **campaign**: numero di contatti avuti con il cliente durante la campagna (numerica);
- **pdays**: numero di giorni trascorsi da quando il cliente era stato contattato per una precedente campagna marketing (numerica);
- **previous**: numero di contatti avuti con il cliente prima dell'attuale campagna marketing (numerica);

Variabile target:

- **y**: il cliente ha sottoscritto un deposito a termine? (binaria).

Carichiamo i Dati:

```
bank <- read.csv("DataS_Bank.csv", sep=",")
View(bank)
```

Controllo la struttura dei dati e la corretta natura delle variabili:

```
str(bank)
```

```
## 'data.frame':    4521 obs. of  8 variables:
##  $ age     : int  30 33 35 30 59 35 36 39 41 43 ...
##  $ balance : int  1787 4789 1350 1476 0 747 307 147 221 -88 ...
##  $ day     : int  19 11 16 3 5 23 14 6 14 17 ...
##  $ duration: int  79 220 185 199 226 141 341 151 57 313 ...
##  $ campaign: int  1 1 1 4 1 2 1 2 2 1 ...
##  $ pdays   : int  -1 339 330 -1 -1 176 330 -1 -1 147 ...
##  $ previous: int  0 4 1 0 0 3 2 0 0 2 ...
##  $ y       : chr  "no" "no" "no" "no" ...
```

```r
head(bank)
```

```
##   age balance day duration campaign pdays previous  y
## 1  30    1787  19       79        1    -1        0 no
## 2  33    4789  11      220        1   339        4 no
## 3  35    1350  16      185        1   330        1 no
## 4  30    1476   3      199        4    -1        0 no
## 5  59       0   5      226        1    -1        0 no
## 6  35     747  23      141        2   176        3 no
```

Controllo le statistiche descrittive:

```r
summary(bank)
```

```
##       age            balance           day           duration
##  Min.   :19.00   Min.   :-3313   Min.   : 1.00   Min.   :   4
##  1st Qu.:33.00   1st Qu.:   69   1st Qu.: 9.00   1st Qu.: 104
##  Median :39.00   Median :  444   Median :16.00   Median : 185
##  Mean   :41.17   Mean   : 1423   Mean   :15.92   Mean   : 264
##  3rd Qu.:49.00   3rd Qu.: 1480   3rd Qu.:21.00   3rd Qu.: 329
##  Max.   :87.00   Max.   :71188   Max.   :31.00   Max.   :3025
##     campaign          pdays          previous           y
##  Min.   : 1.000   Min.   : -1.00   Min.   : 0.0000   Length:4521
##  1st Qu.: 1.000   1st Qu.: -1.00   1st Qu.: 0.0000   Class :character
##  Median : 2.000   Median : -1.00   Median : 0.0000   Mode  :character
##  Mean   : 2.794   Mean   : 39.77   Mean   : 0.5426
##  3rd Qu.: 3.000   3rd Qu.: -1.00   3rd Qu.: 0.0000
##  Max.   :50.000   Max.   :871.00   Max.   :25.0000
```

Verifico se ci sono valori mancanti:

```r
cat("Ci sono valori mancanti?" , any(is.na(bank)))
```

```
## Ci sono valori mancanti? FALSE
```

Da una prima panoramica sui dati, notiamo che ci sono: - 4521 osservazioni e 8 variabili; - 7 variabili numeriche; - 1 target; - Non ci sono valori mancanti.

Il nostro scopo è quello di implementare un modello di regressione logistica per predire se un utente sottoscriverà o meno un deposito.

Per prima cosa procedo a trasformare la mia y, che comprende yes - no, in fattore:

```r
y_bin <- ifelse(bank$y == "yes", 1, 0)
y_bin <- as.factor(y_bin)
summary(y_bin)
```

```
##    0    1
## 4000  521
```

Ora creiamo un grafico per avere una visualizzazione della variabile binaria y_bin:

```r
# Creiamo nuovo dataframe senza colonne duplicate
bank1 <- bank
bank1$y_bin <- y_bin

# Verifichiamo la struttura del dataframe per assicurarci che non ci siano colonne
# duplicate
str(bank1)
```

```
## 'data.frame':    4521 obs. of  9 variables:
##  $ age     : int  30 33 35 30 59 35 36 39 41 43 ...
##  $ balance : int  1787 4789 1350 1476 0 747 307 147 221 -88 ...
##  $ day     : int  19 11 16 3 5 23 14 6 14 17 ...
##  $ duration: int  79 220 185 199 226 141 341 151 57 313 ...
##  $ campaign: int  1 1 1 4 1 2 1 2 2 1 ...
##  $ pdays   : int  -1 339 330 -1 -1 176 330 -1 -1 147 ...
##  $ previous: int  0 4 1 0 0 3 2 0 0 2 ...
##  $ y       : chr  "no" "no" "no" "no" ...
##  $ y_bin   : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
```

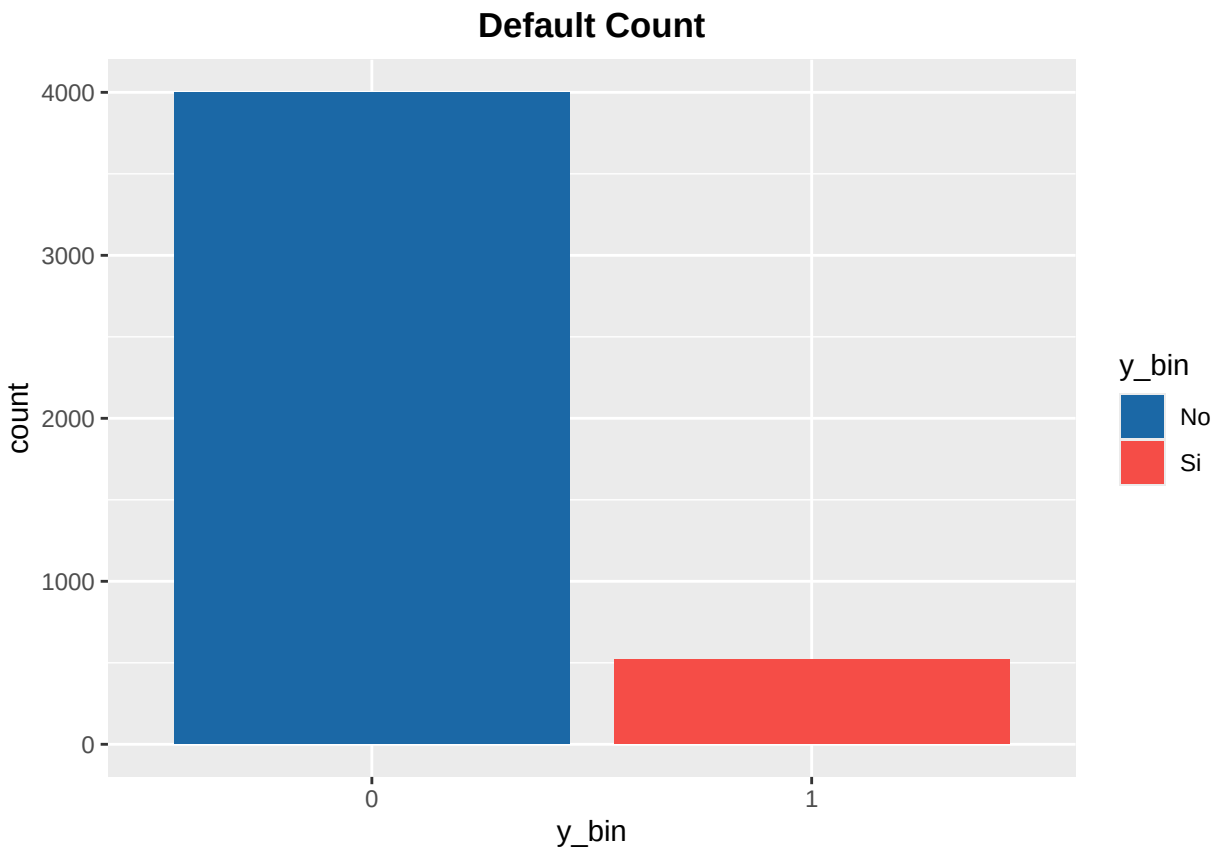
```r
# Verifichiamo che la lunghezza di y_bin sia coerente con il dataframe bank1
print(length(bank1$y_bin))
```

```
## [1] 4521
```

```r
print(nrow(bank1))
```

```
## [1] 4521
```

```r
# Creiamo il grafico a barre con ggplot2
ggplot(bank1, aes(x = y_bin, fill = y_bin)) +
  geom_bar() +
  scale_fill_manual(labels = c('No', 'Si'), values = c("#1B68A6", "#F54D47")) +
  theme(plot.title = element_text(face = 'bold', hjust = 0.5)) +
  ggtitle('Default Count')
```



Successivamente dividiamo il dataset in Training Set, pari al 70% delle osservazioni e Test Set, pari al restante 30% delle osservazioni:

```
n <- nrow(bank1)
idx.est <- sample(1:n, floor(0.7 * n))
train.bank1 <- bank1[idx.est, ] # Training set
test.bank1 <- bank1[-idx.est, ] # Test set
```

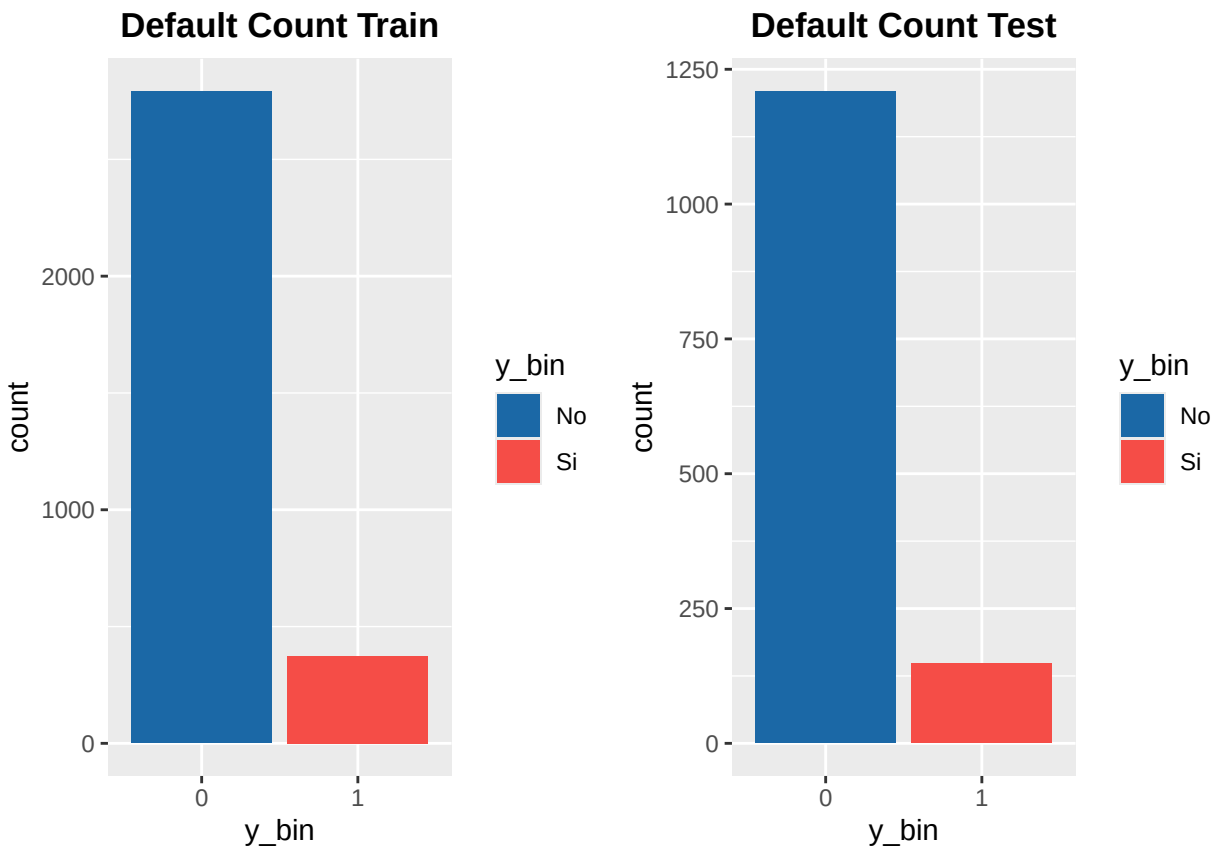
ora andiamo a visualizzare la variabile y_bin sia nel Training set sia nel Test set:

```
par(mfrow=c(2,2))

# conteggio Training set
Count_Train <- ggplot(train.bank1, aes(x = y_bin, fill = y_bin)) +
  geom_bar() +
  scale_fill_manual(labels = c('No', 'Si'), values = c("#1B68A6", "#F54D47")) +
  theme(plot.title = element_text(face = 'bold', hjust = 0.5)) +
  ggtitle('Default Count Train')

# conteggio Test set
Count_Test <- ggplot(test.bank1, aes(x = y_bin, fill = y_bin)) +
  geom_bar() +
  scale_fill_manual(labels = c('No', 'Si'), values = c("#1B68A6", "#F54D47")) +
  theme(plot.title = element_text(face = 'bold', hjust = 0.5)) +
  ggtitle('Default Count Test')
```

```
plot_grid(Count_Train, Count_Test)
```



Analisi di regressione logistica

Stimiamo il modello sul Training Set:

```
reglog = glm(y_bin ~ age + balance + day + duration + campaign + pdays + previous
                ,family=binomial, data = train.bank1)

summary(reglog)
```

```
##
## Call:
## glm(formula = y_bin ~ age + balance + day + duration + campaign +
##     pdays + previous, family = binomial, data = train.bank1)
##
## Coefficients:
##                Estimate  Std. Error z value             Pr(>|z|)
## (Intercept) -4.35516787  0.30153099 -14.444 < 0.0000000000000002 ***
## age          0.02120058  0.00549107   3.861             0.000113 ***
## balance      0.00003154  0.00001639   1.924             0.054362 .
## day          0.01607411  0.00781546   2.057             0.039714 *
## duration     0.00350753  0.00020536  17.080 < 0.0000000000000002 ***
## campaign    -0.09423715  0.03002908  -3.138             0.001700 **
## pdays        0.00146920  0.00060659   2.422             0.015432 *
## previous     0.11047291  0.02940481   3.757             0.000172 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 2295.1  on 3163  degrees of freedom
## Residual deviance: 1864.6  on 3156  degrees of freedom
## AIC: 1880.6
##
## Number of Fisher Scoring iterations: 6
```

Ora eliminiamo le variabili non significative dal modello ed effettuiamo una nuova stima:

```
reglog1 = glm(y_bin ~ age  + duration + campaign + pdays + previous
                ,family=binomial, data = train.bank1)

summary(reglog1)
```

```
##
## Call:
## glm(formula = y_bin ~ age + duration + campaign + pdays + previous,
##     family = binomial, data = train.bank1)
##
## Coefficients:
##               Estimate Std. Error z value             Pr(>|z|)
## (Intercept) -4.0673199  0.2705048 -15.036 < 0.0000000000000002 ***
## age          0.0215721  0.0054763   3.939            0.0000818 ***
## duration     0.0034939  0.0002051  17.038 < 0.0000000000000002 ***
```

```
## campaign    -0.0882068  0.0297377  -2.966             0.003015 **
## pdays        0.0013407  0.0006016   2.229             0.025827 *
## previous     0.1101644  0.0293376   3.755             0.000173 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 2295.1  on 3163  degrees of freedom
## Residual deviance: 1872.0  on 3158  degrees of freedom
## AIC: 1884
##
## Number of Fisher Scoring iterations: 6
```

L'analisi evidenzia che duration, age, day, campaign, pdays e previous sono tutte significative nel determinare il successo di una campagna bancaria. Tuttavia, campaign, ossia il numero di contatti durante la campagna, sembra avere un impatto negativo. Questi risultati possono guidare strategie future per ottimizzare le campagne, focalizzandosi su contatti più mirati e meno frequenti per massimizzare la probabilità di successo.

Ora diamo un'occhiata al McFadden R^2:

Utilizziamo il pacchetto pscl:

```
mcR = pR2(reglog1)[4]
```

```
## fitting null model for pseudo-r2
```

```
mcR
```

```
##  McFadden
## 0.1843787
```

Il McFadden's Pseudo R^2 di 0.2008397, insieme alla significativa riduzione della devianza e al basso valore dell'AIC, indica che il modello di regressione logistica fornisce un adattamento ragionevolmente buono ai dati. Anche se il modello non spiega tutta la variabilità nei dati, riesce comunque a identificare importanti fattori predittivi per il successo della campagna bancaria. Questo risultato è coerente con le aspettative per i modelli di regressione logistica, dove valori di Pseudo R^2 tra 0.2 e 0.4 sono comunemente considerati buoni.

Ora valutiamo la previsione del modello e costruiamo la Confusion-Matrix:

Primo Metodo

Predizione per la confusion-matrix

```
# type='response' indica che si vogliono le probabilità predette
prevision <- predict(reglog1, newdata=test.bank1, type='response')

# digits=10 arrotonda le prob. predette alla decima cifra decimale
prob.pred <- round(prevision, digits = 10)

# creiamo un dataframe per valutare il modello di classificazione
dataframe_test <- cbind(test.bank1, "pr default" = prob.pred)
head(dataframe_test)
```

```
##    age balance day duration campaign pdays previous  y y_bin pr default
## 1   30    1787  19       79        1    -1        0 no     0 0.03791748
## 5   59       0   5      226        1    -1        0 no     0 0.10963274
## 9   41     221  14       57        2    -1        0 no     0 0.04064185
## 13  36    1109  13      328        2    -1        0 no     0 0.08927737
## 17  56    4073  27      239        5    -1        0 no     0 0.07823151
## 18  37    2317  20      114        1   152        2 no     0 0.07344502
```

```
# settiamo il boundary
prevision1 <- ifelse(prevision > 0.5,1,0)
prop.pred <- round(prevision1,digits =10)
dataframe_test <- cbind(test.bank1,"pr default"=prob.pred)
head(dataframe_test)
```

```
##    age balance day duration campaign pdays previous  y y_bin pr default
## 1   30    1787  19       79        1    -1        0 no     0 0.03791748
## 5   59       0   5      226        1    -1        0 no     0 0.10963274
## 9   41     221  14       57        2    -1        0 no     0 0.04064185
## 13  36    1109  13      328        2    -1        0 no     0 0.08927737
## 17  56    4073  27      239        5    -1        0 no     0 0.07823151
## 18  37    2317  20      114        1   152        2 no     0 0.07344502
```

```
summary(prevision1)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## 0.00000 0.00000 0.00000 0.03242 0.00000 1.00000
```

```
# utilizzo il pacchetto caret per plottare la confusion matrix
cm <- confusionMatrix(factor(round(prevision1)), factor(test.bank1$y_bin))

# Funzione per disegnare la matrice di confusione
draw_confusion_matrix <- function(cm) {
  layout(matrix(c(1,1,2)))
  par(mar=c(2,2,2,2))
  plot(c(100, 345), c(300, 450), type = "n", xlab="", ylab="", xaxt='n', yaxt='n')
  title('CONFUSION MATRIX', cex.main=2)

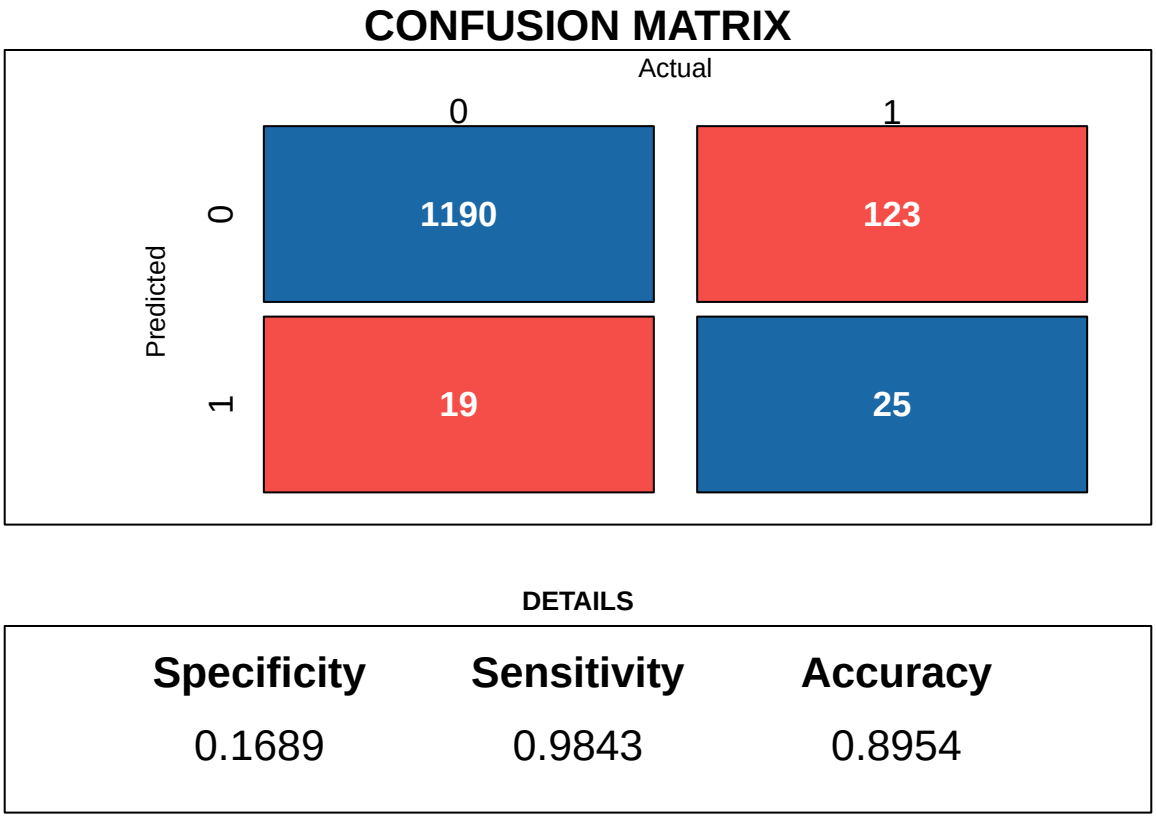
  # creiamo la matrice
  rect(150, 430, 240, 370, col="#1B68A6")
  text(195, 435, '0', cex=1.6)
  rect(250, 430, 340, 370, col="#F54D47")
  text(295, 435, '1', cex=1.6)
  text(125, 370, 'Predicted', cex=1.2, srt=90, font=1)
  text(245, 450, 'Actual', cex=1.2, font=1)
  rect(150, 305, 240, 365, col="#F54D47")
  rect(250, 305, 340, 365, col="#1B68A6")
  text(140, 400, '0', cex=1.6, srt=90)
  text(140, 335, '1', cex=1.6, srt=90)

  # aggiungiamo cm nei risultati
  res <- as.numeric(cm$table)
  text(195, 400, res[1], cex=1.6, font=2, col='white')
```

```
  text(195, 335, res[2], cex=1.6, font=2, col='white')
  text(295, 400, res[3], cex=1.6, font=2, col='white')
  text(295, 335, res[4], cex=1.6, font=2, col='white')

  # aggiungiamo le specifiche
  plot(c(100, 0), c(100, 0), type = "n", xlab="", ylab="", main = "DETAILS", xaxt='n', yaxt='n')
  text(80, 75, names(cm$overall)[1], cex=2, font=2)
  text(80, 35, round(as.numeric(cm$overall[1]), 4), cex=2)
  text(50, 75, names(cm$byClass)[1], cex=2, font=2)
  text(50, 35, round(as.numeric(cm$byClass[1]), 4), cex=2)
  text(20, 75, names(cm$byClass)[2], cex=2, font=2)
  text(20, 35, round(as.numeric(cm$byClass[2]), 4), cex=2)
}

# Disegna la matrice di confusione
draw_confusion_matrix(cm)
```



- **Accuratezza**: Il modello ha un'alta accuratezza dell'88.9%, indicando che la maggior parte delle predizioni sono corrette;
- **Precisione**: La precisione è relativamente bassa al 17.4%, suggerendo che molte delle predizioni positive sono errate;
- **Specificità**: La specificità è alta al 90.2%, significando che il modello è molto efficace nell'identificare le istanze negative reali.

Il modello performa bene in generale, con alta accuratezza e specificità. Questo significa che è molto efficace nel riconoscere i casi negativi. La bassa precisione suggerisce che c'è un alto tasso di falsi positivi, il che significa che molte istanze predette come positive sono in realtà negative.

A conferma dell'accuratezza, abbiamo analizzato la stessa con un ulteriore metodo, i risultati con le due metodologie differiscono di pochi millesimali.

Secondo Metodo

```
fitted.results <- predict(reglog1 ,newdata= test.bank1 ,type='response')
fitted.results <- ifelse(fitted.results > 0.5,1,0)

misClasificError <- mean(fitted.results !=test.bank1$y_bin)
print(paste('Accuracy',1-misClasificError))
```

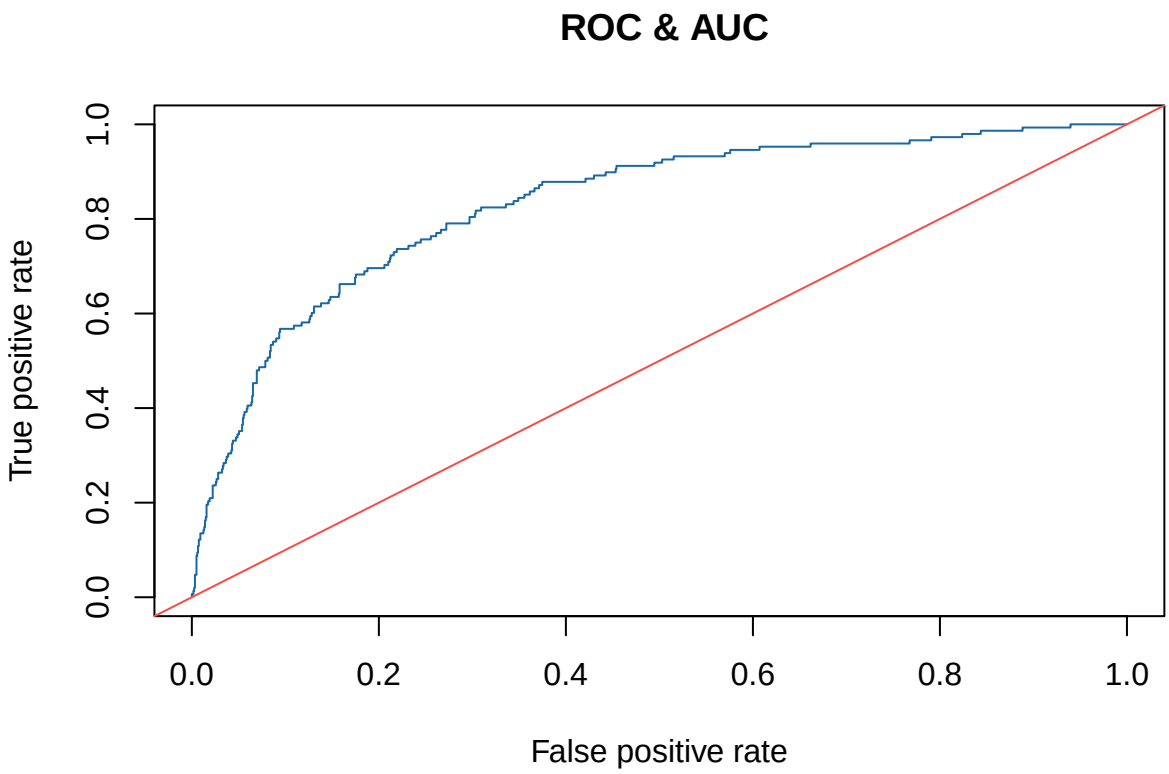
```
## [1] "Accuracy 0.895357406042741"
```

Ora calcoliamo ROC e AUC:

- la curva **ROC** è un grafico che illustra la capacità diagnostica di un modello di classificazione binaria tracciando il tasso di veri positivi (True Positive Rate, TPR) contro il tasso di falsi positivi (False Positive Rate, FPR) a vari valori di soglia;
- l'**AUC** è l'Area Under the Curve (AUC) misura la performance per i modelli di classificazione binaria ed esso varia tra 0 e 1.

```
# utilizziamo la librearia ROCR
p <- prevision1 <- predict(reglog1, newdata = test.bank1, type='response')

pr <- prediction(p, test.bank1$y_bin)
auc <- performance(pr, measure = "auc")
auc <- auc@y.values[[1]]
prf <- performance(pr, measure = "tpr", x.measure = "fpr")
plot(prf, col="#1B68A6" , main = ' ROC & AUC')
abline(0,1, col="#F54D47")
```




```
print(paste0("AUC : ", round(auc, 4)))
```

```
## [1] "AUC : 0.8312"
```

- **ROC**: la curva ROC è ben al di sopra della diagonale, suggerendo che il modello ha una buona capacità di discriminare tra le classi positive e negative. La curva mostra un rapido aumento iniziale, indicando che il modello ha un buon TPR anche per valori bassi di FPR;
- **AUC**: anche se l'immagine non riporta esplicitamente il valore dell'AUC, la forma della curva suggerisce che l'AUC è significativamente maggiore di 0.5, probabilmente attorno a 0.8 o superiore, il che indica una buona performance del modello.

In conclusione, la curva ROC e il probabile alto valore dell'AUC suggeriscono che il modello è efficace nel classificare correttamente le istanze tra le due classi.

Conclusioni

Regressione Multipla: l'analisi di regressione multipla è stata implementata con l'obiettivo di determinare l'influenza delle variabili indipendenti sul prezzo delle case. Per quanto riguarda le variabili, sono risultate tutte significative, eccetto Number of bedrooms. In merito alla performance del modello, l'Adjusted R-squared indica che circa il 91,75% della variabilità nei prezzi delle case è spiegata dalle variabili indipendenti del modello e la Statistica F suggerisce che il modello è altamente significativo.

L'ipotesi di Gauss-Markov sono tutte rispettate e notiamo che i residui seguono una distribuzione approssimativamente normale.

I risultati suggeriscono che le variabili demografiche e strutturali delle case hanno un impatto significativo sui prezzi delle stesse. Questo può guidare strategie di pricing e marketing nel settore immobiliare. Ad esempio:

- Strategie di Pricing: le agenzie immobiliari possono utilizzare queste informazioni per stabilire prezzi più accurati e competitivi. Le case situate in aree con redditi medi più alti possono essere valutate con prezzi superiori;
- Marketing: le campagne di marketing possono essere mirate più efficacemente conoscendo le caratteristiche che aumentano il valore delle case. Le proprietà con più stanze o situate in aree densamente popolate possono essere pubblicizzate come beni di lusso;
- Investimenti: gli investitori immobiliari possono prendere decisioni più informate su dove acquistare o sviluppare nuove proprietà, focalizzandosi su aree con popolazione crescente o redditi medi elevati.

Regressione Logistica: l'analisi di regressione logistica è stata condotta per predire se un cliente sottoscriverà o meno un deposito a termine in base all'impatto delle variabili indipendenti. Procedendo alla stima del modello, abbiamo eliminato le variabili non significative, ossia balance e day. Successivamente abbiamo effettuato una nuova stima dalla quale si è evinto che tutte le variabili hanno un impatto significativo positivo, eccetto campaign il cui impatto è negativo. Infatti, dall'analisi dei coefficienti, abbiamo notato che per ogni contatto aggiuntivo durante la campagna si riduce la probabilità di successo.

Nella valutazione delle performance del modello notiamo che anche se il modello non spiega tutta la variabilità nei dati, riesce comunque a identificare importanti fattori predittivi per il successo della campagna bancaria. Questo risultato è coerente con le aspettative per i modelli di regressione logistica, dove valori di Pseudo R^2 tra 0.2 e 0.4 sono comunemente considerati buoni. Inoltre, la riduzione della devianza e il basso valore dell'AIC (1884) supportano la validità del modello.

La curva ROC mostra che il modello ha una buona capacità di classificare tra le classi positive e negative, con un AUC di 0.8312 maggiore di 0,5 che suggerisce una buona performance del modello.

Mentre, la matrice di confusione indica che il modello ha una buona precisione nel classificare correttamente le istanze.

L'analisi indica che la durata del contatto e la fidelizzazione del cliente sono cruciali per il successo delle campagne bancarie. Ridurre il numero di contatti e focalizzarsi su interazioni di qualità può ottimizzare i risultati delle campagne future.